

# ***Análisis y Clasificación de Actividades Humanas en Video mediante Seguimiento de Articulaciones con MediaPipe***

## **Integrantes**

Santiago Velásquez Holguín - A00372725

Nicholas Villaquirán - A00399069

**Repositorio:** <https://github.com/nicovilla2003/human-activity-tracker.git>

## Resumen / Abstract

**Resumen:** En este proyecto, se desarrollará un sistema de análisis y clasificación de actividades humanas en video mediante la aplicación de técnicas de Inteligencia Artificial. Se emplearán herramientas como Media Pipe y CVAT para registrar, anotar y procesar datos que servirán para entrenar un modelo de clasificación supervisada. Estas herramientas permitirán la extracción de características cinemáticas, tales como velocidades y ángulos articulares, así como diferencias entre frames consecutivos con el fin de analizar tanto movimientos generales (como sentarse, pararse y caminar) como detalles direccionales relacionados con el sentido del movimiento.

**Abstract:** In this project, we will develop a system for human activity analysis and classification in videos through the use of Artificial Intelligence techniques. Tools such as MediaPipe and CVAT will be employed to record, annotate, and process data for the training of a supervised classification model. These tools will enable the extraction of kinematic features, such as velocities, joint angles, as well as frame-to-frame variations, allowing the analysis of both general movements (e.g., sitting, standing, walking) and directional details related to movement orientation.

## I. Introducción

El reconocimiento automático de actividades humanas ha cobrado gran relevancia con los avances en inteligencia artificial y visión por computador, impulsando aplicaciones en rehabilitación, asistencia médica, seguridad y análisis deportivo. Comprender cómo una persona

se mueve puede permitir obtener información valiosa para apoyar decisiones en estos campos. Este tipo de sistemas se apoya de modelos de estimación de pose como MediaPipe Pose u OpenPose, capaces de detectar articulaciones y representar el cuerpo como un conjunto de coordenadas estructuradas. A partir de estas representaciones, los métodos de aprendizaje supervisado permiten entrenar modelos que reconozcan patrones de movimiento con precisión. En este proyecto se busca aprovechar dichas tecnologías para construir una herramienta que clasifique actividades humanas básicas y analice posturas, combinando los enfoques de visión por computador y aprendizaje automático dentro de una metodología sistemática basada en CRISP-DM.

## II. Marco Teórico

El análisis y la clasificación de actividades humanas en video se sustentan en diversas disciplinas de la visión por computador y el aprendizaje automático. La **estimación de pose humana** constituye la base de este tipo de sistemas, ya que permite identificar y localizar puntos clave del cuerpo en imágenes o secuencias de vídeo. A partir de estos puntos, denominados *landmarks*, es posible reconstruir la postura y el movimiento de un individuo en el espacio, facilitando el análisis biomecánico del comportamiento humano.

El **seguimiento articular** complementa este proceso al mantener la coherencia temporal de los puntos clave entre fotogramas consecutivos. Este seguimiento permite calcular magnitudes dinámicas como velocidades, aceleraciones y ángulos articulares, las cuales resultan esenciales para diferenciar entre actividades estáticas,

como estar de pie o sentado, y actividades dinámicas, como caminar o girar. El seguimiento también ayuda a mitigar errores producidos por oclusiones o movimientos rápidos, mejorando la estabilidad de las mediciones.

Una vez extraídas las características biomecánicas de los movimientos, se aplica la **clasificación supervisada**, una técnica de aprendizaje automático en la que un modelo se entrena con ejemplos previamente etiquetados para predecir la categoría o tipo de actividad. En este contexto, algoritmos como *XGBoost* y redes neuronales profundas pueden utilizar los parámetros articulares (por ejemplo, ángulos, distancias relativas o velocidades) como variables de entrada para reconocer gestos o posturas. El desempeño de estos modelos depende en gran medida de la calidad y la representatividad de los datos de entrenamiento, así como de la adecuada selección de hiperparámetros y técnicas de normalización.

Las **métricas de evaluación** permiten cuantificar la efectividad del modelo de clasificación. Entre las más utilizadas se encuentran la *precisión (accuracy)*, el *recall* y el *F1-score*, que permiten medir el equilibrio entre los aciertos y errores del sistema en diferentes clases. En el caso de proyectos con múltiples actividades humanas, es fundamental utilizar evaluaciones balanceadas entre clases para garantizar que el modelo no favorezca las acciones más frecuentes o visualmente dominantes.

En cuanto a las herramientas de estimación de pose, existen diversos enfoques que difieren en su arquitectura, velocidad y nivel de detalle. **OpenPose** es una de las bibliotecas pioneras en este campo,

desarrollada por el *Carnegie Mellon Perceptual Computing Lab*, y se caracteriza por ofrecer alta precisión en la detección de articulaciones múltiples y relaciones corporales complejas. Sin embargo, su alto costo computacional puede dificultar su implementación en tiempo real o en dispositivos de baja potencia. Por otro lado, **MediaPipe**, desarrollada por Google, representa una alternativa más eficiente en entornos de ejecución en tiempo real, gracias a su diseño optimizado y su integración con bibliotecas ligeras. Aunque su precisión puede ser ligeramente menor que la de OpenPose, su rendimiento y facilidad de uso la convierten en una opción ideal para aplicaciones en tiempo real y proyectos con recursos limitados.

En el presente proyecto se seleccionó **MediaPipe** por su capacidad para realizar la detección y el seguimiento de articulaciones de forma estable, rápida y compatible con múltiples plataformas. Su integración con entornos como Python permite automatizar la extracción de *landmarks* y su posterior procesamiento para generar las métricas biomecánicas necesarias en la etapa de clasificación supervisada.

### III. Metodología

El desarrollo del proyecto sigue el enfoque **CRISP-DM (Cross Industry Standard Process for Data Mining)**, un modelo ampliamente utilizado para proyectos de análisis de datos y aprendizaje automático. Este marco metodológico permite organizar el proceso de investigación en fases estructuradas y repetitivas, garantizando coherencia entre los objetivos del estudio,

la preparación de los datos, la modelación y la evaluación de resultados. A continuación, se describe cómo se aplicará cada una de sus etapas al proyecto.

### A. Comprensión del problema

El objetivo del proyecto es diseñar un sistema capaz de **reconocer y clasificar actividades humanas** a partir de videos, mediante el análisis del movimiento corporal y las relaciones biomecánicas entre articulaciones. La problemática principal radica en la necesidad de traducir secuencias visuales complejas en información estructurada que permita identificar posturas o gestos de manera automática y precisa.

Entre los desafíos más relevantes se encuentran la **variabilidad del movimiento humano**, las **diferencias físicas entre individuos**, y la **influencia de factores externos** como la iluminación o el ángulo de grabación, es muy probable que un algoritmo logre identificar el tipo de pose para una persona y no para la otra. Por ello, el modelo deberá ser robusto ante estas variaciones y generalizar correctamente frente a distintos contextos. El propósito final es generar una herramienta que pueda ser utilizada de forma confiable en actividades como rehabilitación física, análisis deportivo o monitoreo de actividades cotidianas.

### B. Recolección y preparación de datos

La fase de recolección de datos se basará en la **captura de videos** de diferentes personas realizando actividades específicas, tales como caminar, sentarse, ponerse de pie y girar. Las grabaciones se realizarán bajo condiciones controladas, procurando variedad en los entornos,

iluminación y ropa, con el fin de generar un conjunto de datos representativo.

Una vez obtenidos los videos, se realizará la **anotación manual de actividades** utilizando la herramienta *CVAT (Computer Vision Annotation Tool)*, que permitirá etiquetar los fotogramas según la acción correspondiente. Posteriormente, se empleará **MediaPipe Pose** para la **extracción automática de landmarks corporales**, obteniendo coordenadas tridimensionales de puntos clave como hombros, caderas, rodillas y tobillos.

Los datos resultantes se normalizarán respecto al centro de las caderas, con el fin de eliminar dependencias de posición o escala, y se almacenarán en archivos estructurados en formato CSV. En la etapa de preparación, se calcularán métricas adicionales como **ángulos articulares**, **velocidades**, **distancias relativas** y **deltas de movimiento**, que servirán como variables de entrada para los modelos de clasificación. Finalmente, se aplicarán técnicas de **filtrado de señal** (Butterworth y Savitzky-Golay) para reducir el ruido y mejorar la calidad de las mediciones.

### C. Selección de herramientas y modelos

El desarrollo técnico se implementará principalmente en **Python**, utilizando bibliotecas especializadas para visión por computador, análisis de datos y aprendizaje automático. Entre las herramientas seleccionadas se incluyen:

- **MediaPipe**, para la detección y seguimiento de articulaciones.
- **CVAT**, para la segmentación y etiquetado manual de videos.

- **Pandas y NumPy**, para el procesamiento y estructuración de datos.
- **Scikit-learn y XGBoost**, para la creación, entrenamiento y ajuste de modelos supervisados.

En esta etapa se explorarán distintos enfoques de modelado, iniciando con clasificadores basados en aprendizaje automático tradicional (como *XGBoost* o *Random Forest*), y posteriormente evaluando arquitecturas más complejas, como redes neuronales densas o recurrentes, que puedan capturar la dependencia temporal del movimiento. La selección final del modelo se definirá según su rendimiento en validación cruzada y su comportamiento en tiempo real.

#### D. Métricas de evaluación

Para medir el desempeño de los modelos, se utilizarán métricas estándar en clasificación supervisada, tales como **precisión (accuracy)**, **recall**, **F1-score** y **matriz de confusión**. Estas métricas permitirán evaluar la capacidad del sistema para distinguir correctamente entre las distintas actividades humanas. Además, se considerará el **tiempo de inferencia** como un indicador clave, dado que el objetivo es lograr una clasificación eficiente en entornos de tiempo real.

Las pruebas iniciales se realizarán sobre un conjunto de validación separado, mientras que los ajustes posteriores de hiperparámetros se llevarán a cabo mediante técnicas de **GridSearchCV** y validación cruzada. El proceso garantizará que el modelo no solo alcance un alto nivel de precisión en los datos de entrenamiento,

sino que también mantenga un rendimiento estable ante nuevas grabaciones.

## IV. Datos y Análisis Exploratorio

En la etapa actual del proyecto, el conjunto de datos se encuentra en fase de **diseño y estructuración**, y aún no se han registrado ejemplos concretos de video. Sin embargo, se ha definido el **plan de captura, formato y estructura de almacenamiento** que guiará la recolección y el procesamiento de la información.

El **origen de los datos** corresponderá a grabaciones realizadas por el equipo de trabajo, en las cuales diferentes participantes ejecutarán actividades humanas básicas, tales como caminar, sentarse, ponerse de pie, girar, acercarse o alejarse de la cámara. Cada grabación se realizará bajo ciertas condiciones, procurando diversidad en el entorno, iluminación, vestimenta y posición de cámara. Los videos se capturarán con una **resolución mínima de 720p**, garantizando una calidad suficiente para la detección precisa de articulaciones mediante **MediaPipe Pose**.

Cada video será procesado para extraer las **coordenadas tridimensionales (x, y, z)** de las principales articulaciones del cuerpo humano, generando así un conjunto de datos estructurado en formato **CSV**. Cada fila del archivo corresponderá a un *frame* de video, y cada columna representará una característica asociada a una articulación o métrica derivada (por ejemplo, ángulos de rodilla, velocidad de cadera o distancia entre hombros). De esta manera, los datos

podrán analizarse tanto en el dominio espacial como en el temporal.

Aunque aún no se dispone de datos numéricos ni ejemplos visuales, se anticipa que el análisis exploratorio incluirá la **verificación de la distribución de valores**, la **detección de posibles outliers**, y la **evaluación de la consistencia de las coordenadas** extraídas por el modelo de pose. Una vez obtenidas las primeras grabaciones, se generarán representaciones gráficas preliminares, tales como **boxplots**, **histogramas** y **curvas de movimiento articular**, con el fin de observar la variabilidad de los datos y definir estrategias de normalización y filtrado.

El conjunto de datos final se dividirá en tres subconjuntos: **entrenamiento (70%)**, **validación (15%)** y **prueba (15%)**, asegurando que cada actividad esté representada de manera balanceada en todas las particiones. Esta estructura permitirá realizar un análisis posterior robusto, evitando sesgos y garantizando una evaluación objetiva del desempeño de los modelos.

Por el momento, el enfoque se centra en **documentar el proceso de adquisición y preprocesamiento**, asegurando que la futura integración de videos y métricas biomecánicas se realice de forma consistente, trazable y compatible con las herramientas de análisis seleccionadas.

## V. Estrategia para Ampliar el Conjunto de Datos

El conjunto de datos estará compuesto por grabaciones realizadas manualmente con el fin de mejorar la capacidad de generalización del modelo y evitar el sobreajuste, planteamos una recopilación mediante el conjunto de grabaciones realizadas durante el transcurso de las entregas hasta tener un dataset completo.

Además de las mismas grabaciones, se aplicarán técnicas de aumento de datos sobre los videos existentes y los nuevos, tales como:

- Rotación y recorte leve del encuadre.
- Variaciones de brillo, contraste y nitidez.
- Simulación de distintos ángulos de cámara.

Estas técnicas permitirán incrementar la variedad del dataset sin perder coherencia en la estructura de las articulaciones detectadas.

En caso de requerir más variabilidad, se considerará incorporar datasets públicos como Human3.6M o UTD-MHAD0, siempre que las licencias permitan su uso académico. La integración se realizará tras la conversión de los datos al mismo formato de landmarks y métricas empleado en el proyecto.

## VI. Aspectos Éticos

Todas las personas que estén involucradas en el proceso de grabar las acciones para el dataset serán informadas previamente sobre el propósito académico del estudio, el uso de sus datos y las medidas de

privacidad adoptadas. En los casos en que las grabaciones incluyan rostros, se aplicarán técnicas de difuminado facial o se utilizarán ángulos de cámara que impidan la identificación de los participantes, priorizando únicamente el registro del movimiento corporal.

Se promueve un uso responsable y ético de la inteligencia artificial, fundamentado en la transparencia de los objetivos del proyecto y en el respeto de los derechos individuales de las personas registradas en los videos. Asimismo, se reconoce la posibilidad de que los datos recolectados presenten sesgos derivados de la falta de diversidad en los participantes o en las condiciones de grabación. Para mitigar este riesgo, se procurará incluir muestras de personas con distintas edades, géneros, complejiones físicas y entornos de captura, con el fin de garantizar un modelo más justo y representativo.

Con el propósito de fomentar la transparencia y la reproducibilidad, los códigos, scripts y procedimientos en el procesamiento y entrenamiento del modelo se mantendrán disponibles en un repositorio público, junto con documentación técnica detallada del proceso experimental. Esto permitirá que otros investigadores puedan replicar los resultados o auditar las decisiones metodológicas adoptadas.

## VII. Próximos Pasos

En la siguiente fase del proyecto se enfocará el trabajo en la **recolección y expansión del conjunto de datos**, grabando nuevos videos que incluyan diferentes personas, perspectivas y

condiciones de iluminación para aumentar la variabilidad y robustez del modelo. A partir de estos datos, se implementará el **preprocesamiento automático de landmarks** utilizando MediaPipe, generando archivos estructurados que sirvan como base para la extracción de características cinemáticas. Posteriormente, se llevará a cabo el **entrenamiento de modelos supervisados**, explorando algoritmos como SVM, Random Forest y XGBoost, acompañados de un proceso de ajuste de hiperparámetros y validación cruzada. Finalmente, se evaluará el desempeño de los modelos mediante métricas como accuracy, precision, recall y F1-score, con el fin de seleccionar la configuración óptima y preparar la fase de **inferencia en tiempo real** que se desarrollará en la última entrega.

## VIII. Resultados

(Dejamos vacío por ahora. Se completará en la Entrega 2 con los resultados de entrenamiento y métricas obtenidas.)

## IX. Análisis de Resultados

(Dejamos vacío por ahora. En la Entrega 3 se incluirá el análisis final de desempeño, comparación con otros autores y posibles mejoras.)

## X. Conclusiones y Trabajo Futuro

(Dejamos vacío por ahora. Se completará al final del proyecto con aprendizajes, limitaciones y propuestas de mejora.)

## XI. Referencias

(Completamos parcialmente) Usar formato IEEE. Incluir fuentes iniciales como documentación de MediaPipe, CVAT y artículos de referencia. Se ampliará en la Entrega 3.

[1] Z. Cao, G. Hidalgo, T. Simon, S.-E. Wei, and Y. Sheikh, "OpenPose: Realtime Multi-Person 2D Pose Estimation using Part Affinity Fields," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 43, no. 1, pp. 172–186, 2021.

[2] "MediaPipe Vs OpenPose - QuickPose.ai," QuickPose.ai, Jul. 26, 2024. [Online]. Available: <https://quickpose.ai/faqs/mediapipe-vs-openpose/>

[3] N. Jirafe, "How to filter noise with a low pass filter — Python," *Analytics Vidhya*, Dec. 27, 2019. [Online]. Available: <https://medium.com/analytics-vidhya/how-to-filter-noise-with-a-low-pass-filter-python-885223e5e9b7>