

Análisis y Clasificación de Actividades Humanas en Video mediante Seguimiento de Articulaciones con MediaPipe

Santiago Velásquez Holguín - A00372725

Nicholas Villaquirán - A00399069

Repositorio:

<https://github.com/nicovilla2003/human-activity-tracker.git>

Resumen / Abstract

Resumen: En este proyecto se desarrolla un sistema de análisis y clasificación de actividades humanas en video mediante técnicas de Inteligencia Artificial. Se utiliza MediaPipe Pose para extraer coordenadas articulares y construir características cinemáticas, como desplazamientos y velocidades de las articulaciones, a partir de videos grabados de actividades básicas (sentarse, ponerse de pie, girar y caminar). Con estos datos se entrenan modelos de clasificación supervisada, entre ellos SVM y Random Forest, obteniendo un desempeño cercano al 78 % de exactitud tras una evaluación por grupos de video. Como trabajo futuro se plantea incorporar herramientas de anotación como CVAT, la inclusión de ángulos articulares e inclinaciones del tronco y un módulo de inferencia en tiempo real basado en cámara web.

Abstract: This project develops a system for human activity analysis and classification in video using Artificial Intelligence techniques. MediaPipe Pose is employed to extract body joint coordinates and build

kinematic features such as joint displacements and approximate velocities from recorded clips of basic activities (sitting, standing up, turning, and walking). These data are used to train supervised classification models, including SVM and Random Forest, achieving an accuracy of about 78 % under group-based evaluation. Future work includes integrating annotation tools such as CVAT, incorporating joint angle and trunk inclination features, and deploying a real-time inference module based on webcam input.

I. Introducción

El reconocimiento automático de actividades humanas ha cobrado gran relevancia con los avances en inteligencia artificial y visión por computador, impulsando aplicaciones en rehabilitación, asistencia médica, seguridad y análisis deportivo. Comprender cómo una persona se mueve permite obtener información valiosa para apoyar decisiones en estos contextos. Este tipo de sistemas se basa en modelos de estimación de pose, como MediaPipe Pose, capaces de detectar articulaciones y representar el cuerpo como un conjunto estructurado de coordenadas.

A partir de estas representaciones, los métodos de aprendizaje supervisado permiten entrenar modelos que reconozcan patrones de movimiento con alta precisión. En este proyecto se implementa un sistema que clasifica actividades humanas básicas y analiza posturas, combinando visión por computador y aprendizaje automático bajo la metodología CRISP-DM, con resultados experimentales que validan su efectividad.

II. Marco Teórico

El análisis y la clasificación de actividades humanas en video combinan fundamentos de visión por computador y aprendizaje automático. La **estimación de pose humana** permite identificar y localizar puntos clave del cuerpo en imágenes o secuencias de video, denominados *landmarks*, a partir de los cuales es posible reconstruir la postura y el movimiento de un individuo. El **seguimiento articular** mantiene la coherencia temporal de estos puntos entre fotogramas consecutivos, posibilitando el cálculo de magnitudes dinámicas como velocidades y ángulos articulares, esenciales para diferenciar actividades estáticas (por ejemplo, estar de pie o sentado) de dinámicas (caminar o girar).

Una vez extraídas las **características cinemáticas**, los modelos de **clasificación supervisada** utilizan ejemplos etiquetados para aprender a predecir la categoría de la actividad. Algoritmos como *Support Vector Machine* (SVM), *Random Forest* o *XGBoost* pueden emplear parámetros articulares (ángulos, distancias relativas, velocidades) como variables de entrada. El desempeño del modelo depende de la calidad del conjunto de datos y de la selección de

hiperparámetros y técnicas de normalización adecuadas.

La efectividad del modelo se evalúa mediante métricas como **accuracy**, **precision**, **recall** y **F1-score**, que miden el equilibrio entre aciertos y errores para cada clase, evitando sesgos hacia actividades más frecuentes o visualmente dominantes.

En cuanto a las herramientas de estimación de pose, **OpenPose**, desarrollada por el *Carnegie Mellon Perceptual Computing Lab*, destaca por su alta precisión y capacidad para detectar múltiples articulaciones, aunque su demanda computacional es elevada. **MediaPipe**, desarrollada por *Google*, ofrece una alternativa optimizada para ejecución en tiempo real, manteniendo buena estabilidad y velocidad. En este proyecto se seleccionó **MediaPipe** por su equilibrio entre rendimiento y precisión, así como por su integración nativa con Python, que facilita la automatización de la extracción y el procesamiento de los *landmarks* necesarios para la etapa de clasificación supervisada.

III. Metodología

El desarrollo del proyecto sigue el enfoque **CRISP-DM (Cross Industry Standard Process for Data Mining)**, ampliamente utilizado para proyectos de análisis de datos y aprendizaje automático. Este modelo organiza el trabajo en fases estructuradas que aseguran coherencia entre los objetivos, la preparación de los datos, la modelación y la evaluación de resultados.

A. Comprensión del problema

El objetivo del proyecto es diseñar un sistema capaz de reconocer y clasificar

actividades humanas a partir de videos, analizando el movimiento corporal y las relaciones biomecánicas entre articulaciones. Entre los principales desafíos se encuentran la variabilidad natural del movimiento humano, las diferencias físicas entre individuos y los efectos de la iluminación o el ángulo de grabación. El modelo debe ser robusto ante estas variaciones para generalizar correctamente en distintos contextos.

B. Recolección y preparación de datos

Se grabaron videos bajo condiciones controladas, con variedad en iluminación y perspectiva, donde una persona realizó actividades básicas como *caminar*, *sentarse*, *ponerse de pie* y *girar*. Los videos se procesaron mediante **MediaPipe Pose**, que permitió obtener coordenadas tridimensionales de 33 puntos articulares por frame. A partir de estos *landmarks* se calcularon **características cinemáticas** simples, como desplazamientos y velocidades articulares.

En futuras fases se planea incorporar **normalización de coordenadas** respecto al centro de las caderas y un **suavizado temporal** (media móvil) para reducir ruido, así como el cálculo de **ángulos articulares** e **inclinaciones del tronco** para mejorar la discriminación entre posturas similares.

C. Selección de herramientas y modelos

La implementación se desarrolló en **Python**, utilizando **MediaPipe**, **Pandas**, **NumPy**, **Scikit-learn** y **Matplotlib**. Se entrenaron y compararon clasificadores tradicionales, principalmente **SVM (RBF)** y **Random Forest**, evaluando su rendimiento en la tarea de clasificación multiclase. En fases posteriores se considerará la integración de herramientas de anotación (CVAT) y modelos más avanzados (XGBoost o redes neuronales) para

capturar dependencias temporales del movimiento.

D. Métricas de evaluación

El desempeño de los modelos se evaluó con métricas estándar de clasificación: **accuracy**, **precision**, **recall**, **F1-score** y **matriz de confusión**. Estas métricas permiten analizar la capacidad del sistema para distinguir correctamente entre las distintas actividades humanas. Además, se consideró el **tiempo de inferencia** como indicador clave de eficiencia en aplicaciones de tiempo real.

En etapas futuras se aplicará un proceso de **ajuste de hiperparámetros (GridSearchCV)** y **validación cruzada**, con el fin de optimizar la generalización del modelo ante nuevas grabaciones.

IV. Datos y Análisis Exploratorio

Se grabaron **24 videos** en cinco categorías de actividad (*caminar hacia la cámara*, *caminar alejándose*, *girar*, *sentarse* y *ponerse de pie*), obteniendo un total de **4 766 frames procesados** mediante **MediaPipe Pose**. A partir de cada video se extrajeron las coordenadas tridimensionales (x, y, z) de **33 puntos articulares** por fotograma, generando un conjunto de datos estructurado en formato **CSV**. La exploración inicial mostró una **detección estable y coherente de las articulaciones** en la mayoría de los clips, con ligeras variaciones asociadas a la iluminación y la distancia a cámara.

Las coordenadas resultantes se utilizaron para calcular **características cinemáticas simples**, como desplazamientos y

velocidades articulares, que evidenciaron patrones distinguibles entre actividades estáticas y dinámicas. En fases posteriores se aplicarán técnicas de normalización y filtrado temporal para reducir ruido y garantizar consistencia entre sesiones.

(Figura 1. Ejemplo de detección articular con MediaPipe Pose o matriz de confusión del modelo Random Forest).

V. Estrategia para Ampliar el Conjunto de Datos

En fases posteriores se ampliará el conjunto de datos mediante la grabación de nuevos videos con **diferentes personas, ángulos de cámara e iluminación**, con el fin de mejorar la capacidad de generalización del modelo. También se considerará aplicar **técnicas de aumento de datos** moderadas, como rotaciones leves o variaciones de brillo, que incrementen la diversidad sin alterar la coherencia de los *landmarks*. Esta expansión permitirá evaluar la robustez del sistema en condiciones reales y evitar el sobreajuste del modelo entrenado.

VI. Aspectos Éticos

Todas las personas que estén involucradas en el proceso de grabar las acciones para el dataset serán informadas previamente sobre el propósito académico del estudio, el uso de sus datos y las medidas de privacidad adoptadas. En los casos en que las grabaciones incluyan rostros, se aplicarán técnicas de difuminado facial o se utilizarán ángulos de cámara que impidan la identificación de los participantes, priorizando únicamente el registro del movimiento corporal.

Se promueve un uso responsable y ético de la inteligencia artificial, fundamentado en la transparencia de los objetivos del proyecto y en el respeto de los derechos individuales de las personas registradas en los videos. Asimismo, se reconoce la posibilidad de que los datos recolectados presenten sesgos derivados de la falta de diversidad en los participantes o en las condiciones de grabación. Para mitigar este riesgo, se procurará incluir muestras de personas con distintas edades, géneros, complejiones físicas y entornos de captura, con el fin de garantizar un modelo más justo y representativo.

Con el propósito de fomentar la transparencia y la reproducibilidad, los códigos, scripts y procedimientos en el procesamiento y entrenamiento del modelo se mantendrán disponibles en un repositorio público, junto con documentación técnica detallada del proceso experimental. Esto permitirá que otros investigadores puedan replicar los resultados o auditar las decisiones metodológicas adoptadas.

En futuras fases se aplicará una matriz de impactos (social, económico, ambiental, global) y una tabla de dilemas éticos según el código de ética profesional.

VII. Próximos Pasos

En la siguiente fase se ampliará el conjunto de datos con nuevas grabaciones que incluyan diferentes personas, condiciones de iluminación y perspectivas, con el fin de mejorar la robustez del modelo. Los datos serán procesados automáticamente mediante **MediaPipe**, generando características cinemáticas (velocidades y


ángulos articulares) para alimentar nuevos modelos de clasificación.

Como parte del **plan de despliegue**, se implementará un módulo de inferencia en tiempo real que capture video desde la cámara web, extraiga *landmarks* y muestre en pantalla la actividad reconocida por el modelo entrenado (**Random Forest**). Esta funcionalidad permitirá evaluar el rendimiento práctico del sistema en condiciones reales. Finalmente, se realizará el **ajuste de hiperparámetros** y la validación cruzada para optimizar la precisión y estabilidad del modelo.

VIII. Resultados


Se entrenaron y evaluaron dos modelos supervisados para la clasificación de actividades humanas a partir de los *landmarks* extraídos con **MediaPipe Pose**: un **SVM con kernel RBF** y un **Random Forest Classifier**. A diferencia de la evaluación inicial, en esta fase se aplicó una partición **por grupos de video**, de manera que los frames de un mismo clip no se compartieran entre los conjuntos de entrenamiento y prueba. Este enfoque evita la fuga de información y proporciona una estimación más realista del rendimiento del sistema.

El **SVM (RBF)** alcanzó un **accuracy de 59.1 %**, con un **F1-score macro de 0.25**, mostrando un sesgo hacia las clases dominantes, en particular *turn* y *walk*. Esto sugiere que la frontera de decisión del modelo no logró separar adecuadamente las clases cuando las características presentan alta correlación temporal y variabilidad entre individuos (Figura 1).



(Figura 1)

Por otro lado, el **Random Forest** logró un **accuracy del 78.0 %**, **precision macro de 0.73**, **recall de 0.51** y **F1-score de 0.51**, evidenciando una mejora significativa en la capacidad de clasificación global. La **matriz de confusión** muestra un reconocimiento más equilibrado entre las categorías *turn* y *walk*, aunque persisten confusiones entre *sit* y *stand*, probablemente por la similitud de sus posturas iniciales (Figura 2).



(Figura 2)

En general, los resultados confirman que los modelos basados en árboles de decisión presentan una mayor robustez

frente al ruido y las variaciones del movimiento, mientras que SVM requiere ajustes adicionales de normalización y de sus hiperparámetros (**C** y **γ**) para mejorar su desempeño. Estos valores servirán como referencia para la optimización y ajuste fino en la siguiente fase del proyecto.

IX. Análisis de Resultados

Los resultados obtenidos evidencian diferencias claras en el comportamiento de los modelos evaluados. El **SVM con kernel RBF** mostró dificultades para separar las clases cuando las características presentan alta correlación temporal, lo que se tradujo en un desempeño limitado (F1-score $\approx$ 0.25). Este resultado sugiere que la normalización de las coordenadas y el ajuste de los hiperparámetros **C** y **γ** serán necesarios para mejorar su capacidad de generalización.

En contraste, el **Random Forest** alcanzó un rendimiento significativamente superior (accuracy $\approx$ 78 %), evidenciando mayor robustez frente a ruido y variabilidad en la ejecución de los movimientos. El modelo logró reconocer adecuadamente las actividades dinámicas (*walk*, *turn*), aunque persisten confusiones entre las clases posturales (*sit*, *stand*), atribuibles a similitudes biomecánicas en sus posiciones iniciales.

Estos resultados confirman la **efectividad del enfoque basado en árboles de decisión** para datos tabulares de landmarks, y sientan la base para la siguiente fase del proyecto, en la que se optimizarán las características de entrada y se evaluará el sistema en escenarios de tiempo real.

(Dejamos incompleto por ahora. En la Entrega 3 se incluirá el análisis final de desempeño, comparación con otros autores y posibles mejoras.)

X. Conclusiones y Trabajo Futuro

El proyecto permitió desarrollar un pipeline funcional para la clasificación de actividades humanas mediante **MediaPipe Pose** y modelos de **aprendizaje supervisado**, obteniendo resultados prometedores sobre un conjunto de datos propio. Se comprobó que **MediaPipe** ofrece una detección articular estable y de bajo costo computacional, adecuada para tareas de análisis de movimiento humano.

El modelo **Random Forest** demostró un desempeño superior frente al SVM, con una precisión global del 78 %, lo que valida su potencial como base para el despliegue en tiempo real.

Como trabajo futuro se plantea:

1. Implementar la **normalización espacial** de coordenadas y un **suavizado temporal** de los landmarks.
2. Incluir **ángulos articulares e inclinaciones del tronco** como nuevas variables biomecánicas.
3. Utilizar herramientas de anotación como **CVAT** para etiquetar clips multiactividad.
4. Desarrollar el **módulo de inferencia en tiempo real**, que integrará el modelo entrenado con la cámara web para la detección y visualización instantánea de actividades.

(Dejamos incompleto por ahora. Se completará al final del proyecto con aprendizajes, limitaciones y propuestas de mejora.)

XI. Referencias

(Completamos parcialmente) Incluimos fuentes iniciales como documentación de MediaPipe, CVAT y artículos de referencia. Se ampliará en la Entrega 3.

[1] Z. Cao, G. Hidalgo, T. Simon, S.-E. Wei, and Y. Sheikh, "OpenPose: Realtime Multi-Person 2D Pose Estimation using Part Affinity Fields," *IEEE Transactions on*

Pattern Analysis and Machine Intelligence, vol. 43, no. 1, pp. 172–186, 2021.

[2] "MediaPipe Vs OpenPose - QuickPose.ai," QuickPose.ai, Jul. 26, 2024. [Online]. Available: <https://quickpose.ai/faqs/mediapipe-vs-openpose/>

[3] N. Jirafe, "How to filter noise with a low pass filter — Python," *Analytics Vidhya*, Dec. 27, 2019. [Online]. Available: <https://medium.com/analytics-vidhya/how-to-filter-noise-with-a-low-pass-filter-python-885223e5e9b7>