

Análisis y Clasificación de Actividades Humanas en Video mediante Seguimiento de Articulaciones con MediaPipe

Santiago Velásquez Holguín - A00372725

Nicholas Villaquirán - A00399069

Repositorio:

<https://github.com/nicovilla2003/human-activity-tracker.git>

Resumen / Abstract

Resumen: En este proyecto se desarrolló un sistema de clasificación de actividades humanas basado en estimación de pose y aprendizaje supervisado. Se recopilaron videos de dos participantes realizando acciones como sentarse, ponerse de pie, girar y caminar, y se extrajeron *landmarks* corporales mediante MediaPipe Pose. Estos fueron normalizados respecto al centro de las caderas y complementados con velocidades cuadro a cuadro para capturar dinámicas de movimiento. Se evaluaron dos modelos (SVM RBF y Random Forest) bajo partición por videos mediante GroupShuffleSplit. El Random Forest obtuvo el mejor desempeño, alcanzando **95.5 % de exactitud** y **0.928 de F1 macro**, mientras que el SVM presentó inestabilidad ante la variabilidad entre sujetos. Finalmente, se implementó un módulo de inferencia en tiempo real integrado con MediaPipe y OpenCV, incluyendo suavizado temporal para estabilizar las predicciones.

Abstract: This project presents a human activity classification system using pose estimation and supervised learning. Videos from two participants performing actions such as sitting, standing, turning, and walking were processed with MediaPipe Pose to extract body landmarks. Landmarks were normalized with respect to the hip center and enriched with frame-to-frame

velocity features. Two models (RBF SVM and Random Forest) were evaluated using GroupShuffleSplit to avoid video-level leakage. The Random Forest achieved **95.5% accuracy** and a **0.928 macro F1-score**, outperforming the SVM, which showed instability under inter-person variability. A real-time inference module was implemented using MediaPipe and OpenCV, incorporating temporal smoothing to stabilize predictions.

I. Introducción

El reconocimiento automático de actividades humanas ha cobrado gran relevancia con los avances en inteligencia artificial y visión por computador, impulsando aplicaciones en rehabilitación, asistencia médica, seguridad y análisis deportivo. Comprender cómo una persona se mueve permite obtener información valiosa para apoyar decisiones en estos contextos. Este tipo de sistemas se basa en modelos de estimación de pose, como MediaPipe Pose, capaces de detectar articulaciones y representar el cuerpo como un conjunto estructurado de coordenadas. A partir de estas representaciones, los métodos de aprendizaje supervisado permiten entrenar modelos que reconozcan patrones de movimiento con alta precisión. En este proyecto se implementa un sistema que clasifica actividades humanas básicas y analiza posturas, combinando visión por computador y

aprendizaje automático bajo la metodología CRISP-DM, además de un módulo de inferencia en tiempo real basado en cámara web.

II. Marco Teórico

El análisis y la clasificación de actividades humanas en video combinan fundamentos de visión por computador y aprendizaje automático. La **estimación de pose humana** permite identificar y localizar puntos clave del cuerpo en imágenes o secuencias de video, denominados *landmarks*, a partir de los cuales es posible reconstruir la postura y el movimiento de un individuo. El **seguimiento articular** mantiene la coherencia temporal de estos puntos entre fotogramas consecutivos, posibilitando el cálculo de magnitudes dinámicas como velocidades y ángulos articulares, esenciales para diferenciar actividades estáticas (por ejemplo, estar de pie o sentado) de dinámicas (caminar o girar).

Una vez extraídas las **características cinemáticas**, los modelos de **clasificación supervisada** utilizan ejemplos etiquetados para aprender a predecir la categoría de la actividad. Algoritmos como *Support Vector Machine* (SVM), *Random Forest* o *XGBoost* pueden emplear parámetros articulares (ángulos, distancias relativas, velocidades) como variables de entrada. El desempeño del modelo depende de la calidad del conjunto de datos y de la selección de hiperparámetros y técnicas de normalización adecuadas.

La efectividad del modelo se evalúa mediante métricas como **accuracy**, **precision**, **recall** y **F1-score**, que miden el equilibrio entre aciertos y errores para cada clase, evitando sesgos hacia actividades más frecuentes o visualmente dominantes.

En cuanto a las herramientas de estimación de pose, **OpenPose**, desarrollada por el *Carnegie Mellon Perceptual Computing Lab*, destaca por su alta precisión y capacidad para detectar múltiples articulaciones, aunque su demanda computacional es elevada. **MediaPipe**, desarrollada por *Google*, ofrece una alternativa optimizada para ejecución en tiempo real, manteniendo buena estabilidad y velocidad. En este proyecto se seleccionó **MediaPipe** por su equilibrio entre rendimiento y precisión, así como por su integración nativa con Python, que facilita la automatización de la extracción y el procesamiento de los *landmarks* necesarios para la etapa de clasificación supervisada.

III. Metodología

El proyecto siguió el enfoque CRISP-DM, estructurando el desarrollo en etapas que abarcan la comprensión del problema, la preparación de datos, la modelación, la evaluación y el despliegue final.

A. Comprensión del problema

El objetivo es diseñar un sistema capaz de reconocer actividades humanas básicas a partir de secuencias de video mediante estimación de pose. El principal reto consiste en la variabilidad inter-e intrapersonal del movimiento humano y en las diferencias producidas por iluminación, ropa y orientación respecto a la cámara. Para que el sistema generalice correctamente, el procesamiento debe minimizar dependencias del entorno y capturar tanto la postura estática como la dinámica del movimiento.

B. Recolección y preparación de datos

Se grabaron videos de dos participantes realizando las actividades de interés (sentarse, ponerse de pie, girar y caminar). A cada video se le extrajeron 33 *landmarks* por frame utilizando MediaPipe Pose. Para reducir la dependencia de la posición absoluta en la imagen, las

coordenadas se normalizaron restando el centro de las caderas (l23, l24). Además, se incluyeron características dinámicas calculando velocidades cuadro a cuadro mediante diferencias entre frames.

Los datos procesados fueron organizados en archivos CSV y combinados en un único dataset, preservando la información del video de origen para evitar fuga de información. Esta preparación permitió capturar tanto la geometría corporal como las variaciones temporales asociadas a cada actividad.

C. Selección de herramientas y modelos

La implementación se realizó en Python utilizando MediaPipe, NumPy, Pandas y Scikit-learn. Se entrenaron dos clasificadores: un SVM con kernel RBF y un Random Forest. Para evitar que frames del mismo video aparecieran en entrenamiento y prueba, la evaluación se realizó mediante GroupShuffleSplit, usando el nombre del video como grupo.

El Random Forest fue ajustado manualmente variando hiperparámetros como número de árboles, profundidad máxima, tamaño mínimo de hoja y balanceo de clases. Esta configuración ofreció el mejor compromiso entre precisión y estabilidad, alcanzando el desempeño más alto del proyecto.

D. Métricas de evaluación

El rendimiento se midió utilizando accuracy, precisión macro, recall macro, F1-score macro y matrices de confusión. Estas métricas permitieron evaluar el comportamiento del modelo de manera equilibrada entre clases, considerando que algunas actividades presentan menos variabilidad visual.

Además, para el módulo en tiempo real se consideró la estabilidad de la predicción como

criterio adicional. Con este fin se incorporó un suavizado temporal basado en una ventana deslizante de predicciones recientes.

E. Despliegue en tiempo real

Se desarrolló un módulo de inferencia en tiempo real utilizando OpenCV para la captura de video y MediaPipe Pose para la detección continua de *landmarks*. El vector de características de cada frame reproduce exactamente el esquema usado durante el entrenamiento (normalización por caderas y velocidades), garantizando coherencia entre ambas fases. El clasificador entrenado se cargó desde un archivo serializado y se aplicó un suavizado temporal para evitar fluctuaciones rápidas entre etiquetas. Este módulo permite demostrar visualmente la funcionalidad del sistema y evaluar su comportamiento bajo condiciones reales.

IV. Datos y Análisis Exploratorio

Se grabaron **42 videos** en cinco categorías de actividad (*caminar hacia la cámara, caminar alejándose, girar, sentarse y ponerse de pie*), obteniendo un total de **7800 frames procesados** mediante **MediaPipe Pose**. Se utilizaron tres participantes distintos para mejorar la diversidad corporal. A partir de cada video se extrajeron las coordenadas tridimensionales (x, y, z) de **33 puntos articulares** por fotograma, generando un conjunto de datos estructurado en formato CSV. La exploración inicial mostró una **detección estable y coherente de las articulaciones** en la mayoría de los clips, con ligeras variaciones asociadas a la iluminación y la distancia a cámara.

Las coordenadas resultantes se utilizaron para calcular **características cinemáticas simples**, como desplazamientos y velocidades articulares, que evidenciaron patrones distinguibles entre actividades estáticas y dinámicas. Es clave mencionar que la detección del MediaPipe se

mantuvo estable para la mayoría de los clips, para las actividades como caminar y girar muestran patrones de velocidad marcados, mientras que los posturales requieren información espacial adicional.

(Figura 1. Ejemplo de detección articular con MediaPipe Pose o matriz de confusión del modelo Random Forest).

V. Estrategia para Ampliar el Conjunto de Datos

Para la última entrega se realizó un plan para expandir el dataset, el cual incluyó los siguientes cambios:

A. Grabación de nuevos videos.

Se aumentó la cantidad de videos para entrenar el modelo de manera más robusta.

B. Nuevos participantes.

Se incorporaron nuevos participantes para mejorar la capacidad del modelo identificando actividades con diferentes tipos de cuerpos.

C. Variaciones de ángulos de cámara y distancias.

Se cambió el ángulo con la distancia para mejorar el rango con el que el modelo funciona.

D. Variaciones de ropa, iluminación y objetos a la vista

Se cambiaron aspectos físicos como ropa, iluminación y objetos para preparar al modelo en diferentes escenarios de ejecución.

VI. Aspectos Éticos

Todas las personas que estén involucradas en el proceso de grabar las acciones para el dataset serán informadas previamente sobre el propósito académico del estudio, el uso de sus datos y las medidas de privacidad adoptadas. En los casos

en que las grabaciones incluyan rostros, se aplicarán técnicas de difuminado facial o se utilizarán ángulos de cámara que impidan la identificación de los participantes, priorizando únicamente el registro del movimiento corporal.

Se promueve un uso responsable y ético de la inteligencia artificial, fundamentado en la transparencia de los objetivos del proyecto y en el respeto de los derechos individuales de las personas registradas en los videos. Asimismo, se reconoce la posibilidad de que los datos recolectados presenten sesgos derivados de la falta de diversidad en los participantes o en las condiciones de grabación. Para mitigar este riesgo, se procurará incluir muestras de personas con distintas edades, géneros, complejiones físicas y entornos de captura, con el fin de garantizar un modelo más justo y representativo.

Con el propósito de fomentar la transparencia y la reproducibilidad, los códigos, scripts y procedimientos en el procesamiento y entrenamiento del modelo se mantendrán disponibles en un repositorio público, junto con documentación técnica detallada del proceso experimental. Esto permitirá que otros investigadores puedan replicar los resultados o auditar las decisiones metodológicas adoptadas.

Cabe mencionar que se mantendrá la privacidad del usuario mediante un sistema que no almacena videos, no guarda imágenes ni detalles biométricos, todo es entrenado antes de la utilización del modelo.

VII. Resultados

Se evaluaron dos modelos supervisados para la clasificación de actividades humanas utilizando los *landmarks* procesados de MediaPipe Pose. Para evitar fuga de información entre entrenamiento y prueba, la evaluación se realizó mediante **GroupShuffleSplit**, garantizando que

los frames de un mismo video no se mezclaran entre particiones.

SVM (RBF).


El SVM obtuvo un desempeño limitado, con un **accuracy de 34.2 %** y un **F1 macro de 0.128**. La matriz de confusión (Figura 2) muestra que el modelo tiende a predecir mayoritariamente la clase *walk*, sin lograr separar adecuadamente las transiciones posturales ni la variabilidad entre participantes (Figura 1). Esto indica que la frontera de decisión del SVM no captura bien la estructura no lineal de las características cinemáticas.

```

=== SVM (RBF) ===
Accuracy: 0.342
Precision (macro): 0.086
Recall (macro): 0.250
F1-score (macro): 0.128

```

(Figura 1)



(Figura 2)

Random Forest (tuned).

El modelo ajustado alcanzó un rendimiento significativamente superior, con **95.8 % de exactitud**, **0.933 de precisión macro**, **0.931 de recall macro** y un **F1 macro de 0.932**. La matriz de confusión (Figura 3) evidencia una


clasificación estable y equilibrada entre todas las actividades, con ligeras confusiones entre *sit* y *stand*, atribuibles a su similitud postural. El modelo mostró especial solidez al reconocer *turn* y *walk*, incluso frente a variaciones de orientación y apariencia entre personas (Figura 4).

```

=== RandomForest (tuned) ===
Accuracy: 0.958
Precision (macro): 0.933
Recall (macro): 0.931
F1-score (macro): 0.932


```

(Figura 3)



(Figura 4)


En conjunto, los resultados confirman que los métodos basados en árboles ofrecen mayor



robustez ante ruido, diferencias interpersonales y variabilidad temporal, mientras que SVM requeriría una normalización más agresiva y ajustes extensivos de hiperparámetros para alcanzar un rendimiento competitivo.

VIII. Análisis de Resultados


Los resultados obtenidos muestran diferencias marcadas entre ambos modelos y permiten entender mejor el comportamiento del sistema frente a la variabilidad del movimiento humano. El **SVM con kernel RBF** (Figura 2) presentó un desempeño insuficiente ($F1 \text{ macro} = 0.128$), tendiendo a predecir de forma predominante la clase *walk*. Esto indica que el modelo no logró capturar las relaciones no lineales entre *landmarks* ni las variaciones temporales de las actividades. Además, la orientación corporal respecto a la cámara afectó de forma significativa su estabilidad: cuando el participante caminaba hacia la cámara, las predicciones se confundían con *stand*, mientras que al caminar dándole la espalda, la clasificación se volvía más consistente (Figura 5).



(Figura 6)

En contraste, el **Random Forest** ajustado obtuvo un rendimiento notablemente superior

($\text{accuracy} = 95.8 \%$, $F1 \text{ macro} = 0.932$). Su matriz de confusión (Figura 3) muestra una separación casi perfecta entre actividades dinámicas (*walk*, *turn*), y errores residuales entre *sit* y *stand*, esperables debido a similitudes biomecánicas en la transición entre ambas posturas. El modelo demostró mayor robustez ante diferencias entre participantes, alturas, proporciones corporales y condiciones de iluminación, lo que sugiere que sus reglas internas capturan relaciones relevantes entre coordenadas normalizadas y sus velocidades.



(Figura 6)

En el sistema de tiempo real (Figuras 5–7), el rendimiento observado coincide con los resultados offline: *turn* y *walk* son detectadas de manera estable, mientras que *sit* y *stand* dependen fuertemente de la transición y de la alineación del torso con la cámara. El suavizado temporal incorporado reduce oscilaciones indeseadas y mejora la coherencia temporal de las predicciones.

Estos hallazgos confirman que los métodos basados en árboles de decisión son especialmente adecuados para datos tabulares derivados de pose, mientras que SVM requeriría una normalización más agresiva, ingeniería de características adicionales (p. ej., ángulos

articulares) y ajuste extensivo de hiperparámetros. En conjunto, el sistema final demuestra un alto nivel de generalización y establece una base sólida para futuras mejoras centradas en direccionalidad y modelado explícito de secuencias.

IX. Conclusiones y Trabajo Futuro

El proyecto permitió desarrollar un pipeline funcional para la clasificación de actividades humanas mediante **MediaPipe Pose** y modelos de **aprendizaje supervisado**, obteniendo resultados prometedores sobre un conjunto de datos propio. Se comprobó que **MediaPipe** ofrece una detección articular estable y de bajo costo computacional, adecuada para tareas de análisis de movimiento humano.

El modelo **Random Forest** demostró un desempeño superior frente al SVM, con una precisión global del 95%, lo que valida su potencial como modelo competitivo considerando la simplicidad de las características empleadas.

Como trabajo futuro se plantea:

1. Caminatas direccionales con múltiples ángulos para evitar sesgos
2. Anotación con CVAT para etiquetar secuencias largas y actividades compuestas.

3. Características biomecánicas más complejas (ángulos, aceleraciones, centros de masa).

4. Integración de un sistema multi-persona en tiempo real.

X. Referencias

(Completamos parcialmente) Incluimos fuentes iniciales como documentación de MediaPipe, CVAT y artículos de referencia. Se ampliará en la Entrega 3.

[1] Z. Cao, G. Hidalgo, T. Simon, S.-E. Wei, and Y. Sheikh, "OpenPose: Realtime Multi-Person 2D Pose Estimation using Part Affinity Fields," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 43, no. 1, pp. 172–186, 2021.

[2] "MediaPipe Vs OpenPose - QuickPose.ai," QuickPose.ai, Jul. 26, 2024. [Online]. Available: <https://quickpose.ai/faqs/mediapipe-vs-openpose/>

[3] N. Jirafe, "How to filter noise with a low pass filter — Python," *Analytics Vidhya*, Dec. 27, 2019. [Online]. Available: <https://medium.com/analytics-vidhya/how-to-filter-noise-with-a-low-pass-filter-python-885223e5e9b7>